1. Efek regularisasi Pada batch normalisasi
   Pada setiap mini batch normalisasi menghitung rata rata dab varian dari batch tersebut, bukan dari seluruh populasi data. Akibatnya aktivasi sebuah sampel yang dinormalisasi memakai statistic lebih bergantung pada sampel dalam batch yang sama. Sehingga sampel yang sama sedikit berbeda di setiap pengulangan. Variasi ini menjadi noise stokastik yang menyerupai regularisasi

   Asumsi menghilangkan dropout tidak berlaku ketika
   - Batch sangat kecil sehingga estimasi statistic terlalu banyak noise dan pelatihan menjadi tidak stabil
   - Dropout ditempatkan sebelum BN, karena perbedaan varians antara fase training dan inference menimbulkan variance shift
   - Model besar dilatih pada data sangat besar, sehingga overfitting tetap terjadi dan Dropout pada fully connected layer masih diperlukan
2. Degradasi Jaringan dalam dan formulasi residual
   Pada CNN lapisan tambahan harus mempelajari identitas mapping melalui tumpukan transformasi non linear dan hal ini sulit dicapai oleh optimizer. Karena training error ikut naik, degradation problem merupakan masalah optimasi dan bukan overfitting

   Pada CNN gradien merupakan hasil perkalian banyak Jacobian jika norma tiap faktor kurang dari 1 makan akan terjadi vanishing gradien
3. Feature Extraction vs fine tuning
   Train able parameter : feature extraction hanya melatih head 5130 parameter pada resnet18 sedangkan fine tuning layer 4 dan fc melatih 8383858 parameter. Volume data : feature extraction cukup dengan data sedikit karena kapasitas yang dilatih kecil sedangkan fine tuning membutuhkan data lebih banyak afar tidak terjadi fine tuning. Komputasi feature Extraction lebih ringan karena gradien dari head yang masih acak dan dapat merusak fitur bawaan sehingga diperlukan learning rate yang lebih kecil

   Kesimpulannya pilih feature extraction bila data terbatas dan domain mirip Imagenet dan pilih fine tuning jika data cukup atau domain target berbeda dari imageNEt
4. Penerapan data augmentasi
   Augmentasi bertujuan untuk memperluas variasi data latih agar model belajar invariant terhadap tarnsformasi tertentu. Validation dan test set berfungsi sebagai estimator performa pada data nyata yang tidak dimanipulasi Jika Augmentasi secara acak, metrik menjadi non-deterimistik, sulit dibandingkan antar eksperimen, tidak lagi mewakili distribusi data produksi, dan membuat early stopping berbasis validation loss menjadi bias. Pada evaluasi transformasi deterimistik yang digunakan seperti resize, centercrop normalisai

   Contoh transformasi yang tidak layak Perubahan hue yang kuat atau konversi grayscale pada klasifikasi pet breeds, warna dan pola bulu merupakan fitur penentu label . Mengubahnya dapat membuat label tidak sesuai dengan karakteristik nya sehingga terjadi pelanggaran invariansi semantic table
5. Mitigasi Catastrophic forgetting
   Catastropic forgetting terjadi ketika bobot pretrained diperbarui terlalu agresif(learning rate besar atau gradien besar dari head acak), sehingga parameter bergesar jauh dari optimum pretraining karena data target kecil dan sempit. Bobotnya hanya dioptimalkan untuk tugas baru dan fitur umum hasil image net

- Strategi 1 diferential learning rate : layer 4 memakai learning rate kecil dan fc memakai nilai lebih besar karena fitur generic perlu dirubah minimal sedangkan head acak butuh Langkah lebih besar
- Strategi 2 gradual Unfreezing head dilatih lebih dahulu lalu lapisan dibuka dari atas ke bawah setelah head stabil, gradien yang mengalir backbone menjadi kecil dan ter arah, sehingga fitur pretrained terlindungi