Laporan

Nama: Vincent Vibhava Pranata | NIM: 2802415523 | Mata Kuliah: Deep Learning | Repositori: https://github.com/VincentVibhavaPranata/Deep-learning

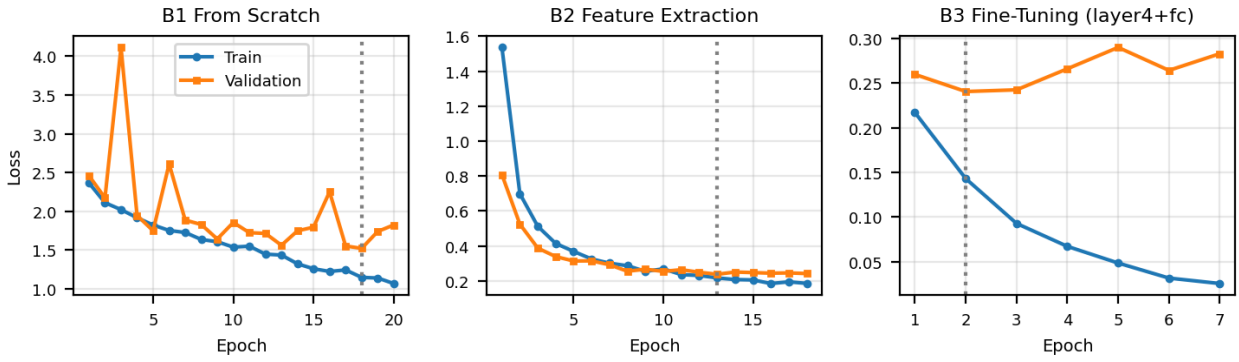
1. Setup Eksperimen

Dataset yang digunakan adalah subset 10 kelas Oxford-IIIT Pet: 5 ras kucing (Abyssinian, Bengal, Birman, Bombay, British Shorthair) dan 5 ras anjing (American Bulldog, American Pit Bull Terrier, Beagle, Boxer, Chihuahua), total 1.981 citra. Data dibagi secara stratified 70/15/15 menjadi 1.386 citra latih, 297 validasi, dan 298 uji. Seluruh kondisi memakai ResNet-18 (bobot IMAGENET1K_V1 untuk B2–B4), input 224×224 dengan normalisasi ImageNet, batch size 32, AdamW (weight decay 1e-2), CrossEntropyLoss, early stopping pada validation loss (patience 5, maksimum 20 epoch), dan seed 42. Bobot epoch terbaik dipulihkan sebelum evaluasi test. Catatan: pipeline B1–B3 sudah memakai augmentasi pada train set; B4 mengisolasi efek augmentasi pada konfigurasi B3. Kondisi B5 (bonus) tidak dilaksanakan. Seluruh angka di bawah bersumber dari berkas *all_metrics_consolidated.csv* dan log pelatihan per kondisi.

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Kode	Strategi	Trainable params	Learning rate	Epoch (terbaik / total)	Waktu (detik)	Val Acc*	Gap train-val*	Test Acc	Macro F1 test
B1	From scratch, semua layer	11.181.642	1e-3	18 / 20	286,7	0,4949	0,112	0,5201	0,4906
B2	Feature extraction (hanya fc)	5.130	1e-3	13 / 18	295,9	0,9192	0,021	0,9396	0,9396
B3	Fine-tuning layer4 + fc	8.398.858	1e-4 (layer4), 1e-3 (fc)	2 / 7	119,1	0,9327	0,031	0,9396	0,9397
B4-a	B3 tanpa augmentasi	8.398.858	1e-4 / 1e-3	4 / 9	84,6	0,9461	0,051	0,9362	0,9360
B4-b	B3 dengan augmentasi	8.398.858	1e-4 / 1e-3	4 / 9	122,3	0,9461	0,023	0,9262	0,9262
B5	Tidak dilaksanakan (bonus)	–	–	–	–	–	–	–	–

**Val Acc dan gap (train acc − val acc) diukur pada epoch dengan validation loss terendah, yaitu bobot yang dipakai pada evaluasi test. Waktu B2 dari output notebook (295,94 detik).*



Gambar 1. Kurva training loss vs. validation loss untuk B1, B2, dan B3 (garis putus-putus: epoch terbaik).

C2. Pembahasan Analisis Komparatif

(1) Disparitas B1 terhadap B2 dan B3 Macro F1 B1 hanya 0,4906, sedangkan B2 dan B3 mencapai 0,9396 dan 0,9397, selisih sekitar 45 poin. Arsitekturnya identik (ResNet-18 dengan skip connection), sehingga jurang ini bukan berasal dari kedalaman jaringan, melainkan dari inisialisasi: skip connection membuat optimasi jaringan dalam menjadi mungkin, tetapi tidak menggantikan data. Dengan 1.386 citra latih, 11,2 juta parameter tidak cukup terkonstrain untuk belajar fitur visual dari nol, sedangkan bobot pretrained sudah membawa fitur tepi, tekstur, dan bagian objek dari ImageNet yang relevan untuk citra kucing dan anjing. Pada Gambar 1, training loss B1 masih menurun hingga epoch 20, validation loss terbaiknya baru muncul di epoch 18 (dengan fluktuasi besar), dan batas 20 epoch tercapai tanpa early stopping, sehingga B1 belum sepenuhnya konvergen dan besar selisih sebagian dipengaruhi anggaran epoch.

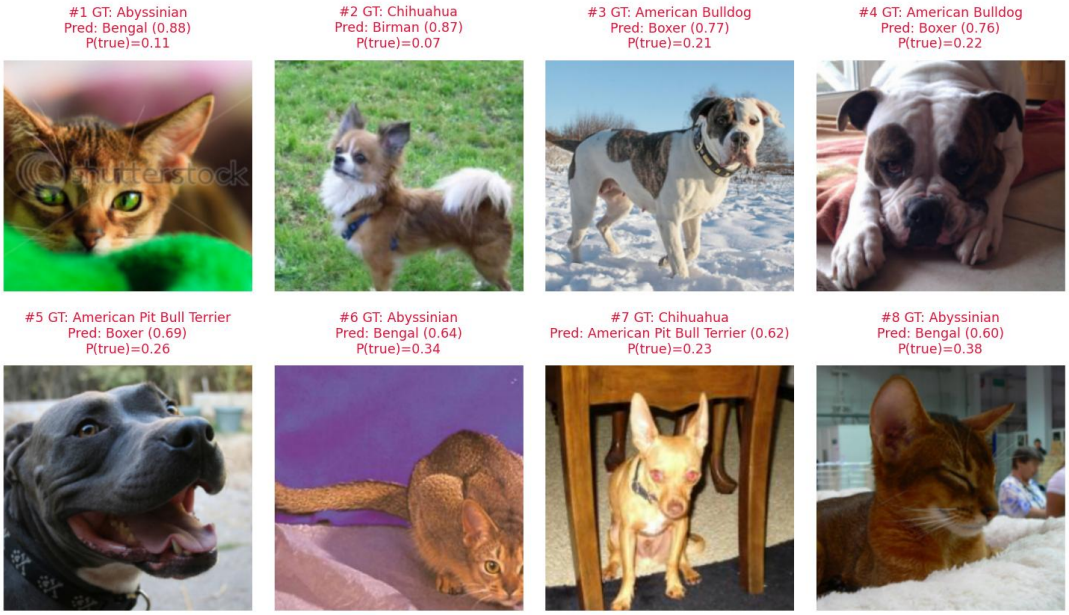
(2) Feature extraction vs. fine-tuning Pada data ini keduanya setara: Macro F1 test 0,9396 (B2) dan 0,9397 (B3), selisih 0,0001 tidak bermakna, dan akurasi test identik (280 dari 298 benar). Perbedaannya ada pada perilaku

pelatihan. B2 melatih 5.130 parameter, konvergen lambat namun mulus (epoch terbaik ke-13). B3 melatih 8.398.858 parameter dan mencapai validation loss terbaik pada epoch ke-2, lalu tidak membaik lagi pada epoch 3–7, artinya kapasitas tambahan cepat mulai menyesuaikan diri ke data latih dan pelatihan sangat bergantung pada early stopping. Val Acc B3 sedikit lebih tinggi (0,9327 vs 0,9192), tetapi selisih 1,4 poin setara sekitar 4 citra dari 297. Total waktu B3 lebih singkat (119 vs 296 detik) hanya karena berhenti lebih awal; waktu per epoch hampir sama (17,0 vs 16,4 detik), sehingga pembekuan backbone tidak menghemat waktu per epoch pada setup ini. Dugaan kami, penyebabnya adalah bottleneck data loading dan augmentasi di CPU Colab (num_workers=2), namun hal ini belum diuji langsung.

(3) Peran augmentasi (Slide 20). Pada B4, augmentasi mengecilkan generalization gap lebih dari separuh, dari 0,051 menjadi 0,023, dan menurunkan train accuracy dari 0,997 menjadi 0,969, sesuai peran augmentasi sebagai regularizer. Namun Val Acc tidak berubah (0,9461 pada keduanya), validation loss sedikit lebih tinggi (0,2117 vs 0,1999), dan Macro F1 test justru turun dari 0,9360 ke 0,9262 (selisih ±3 citra dari 298). Selisih ini tidak dapat dianggap bukti bahwa augmentasi merugikan: B3 dan B4-b memiliki konfigurasi yang sama, namun Macro F1 test-nya berbeda 0,0135 (0,9397 vs 0,9262), lebih besar daripada efek augmentasi yang diukur. Kesimpulan yang dapat dipertanggungjawabkan hanya bahwa augmentasi menurunkan overfitting pada train set tanpa perbaikan akurasi yang terukur pada subset 10 kelas ini. Augmentasi juga menaikkan waktu per epoch dari 9,4 menjadi 13,6 detik.

C3. Failure Analysis

Model terbaik adalah B3 (Macro F1 tertinggi, walau berbeda tipis dari B2). Terdapat 18 citra test yang salah diprediksi (298 − 280 benar). Delapan sampel di bawah dipilih berdasarkan confidence tertinggi pada prediksi yang salah, karena kesalahan yang yakin paling informatif. Seluruhnya memiliki P(true) di bawah 0,40, dan hanya sampel #8 yang relatif mendekati batas keputusan. Hipotesis pada tabel belum diuji (misalnya dengan Grad-CAM) sehingga bersifat dugaan.



Gambar 2. Delapan kesalahan prediksi dengan confidence tertinggi pada test set (model B3).

#	GT → Prediksi (conf; P(true))	Hipotesis penyebab
1	Abyssinian → Bengal (0,88; 0,11)	Close-up ekstrem tanpa pola bulu tubuh yang terlihat, watermark, dan latar hijau jenuh. Bulu cokelat keemasan kucing ras berbulu pendek mirip Bengal (ambiguitas visual antar ras, bias latar belakang).
2	Chihuahua → Birman (0,87; 0,07)	Chihuahua berbulu panjang dengan ekor putih lebat dan latar rumput luas. Bulu panjang dan titik putih menyerupai kucing Birman, sementara subjek kecil di dalam frame (varian atipikal, bias latar belakang).
3	American Bulldog → Boxer (0,77; 0,21)	Tubuh penuh dengan corak putih dan brindle pada latar salju dengan pencahayaan kebiruan. Warna dan corak mirip Boxer, dan subjek berukuran kecil sehingga detail kepala kurang jelas.
4	American Bulldog → Boxer (0,76; 0,22)	Posisi berbaring dengan sebagian tubuh tidak terlihat (oklusi) dan wajah berkerut berhidung pendek yang mirip Boxer. Ras anjing bertubuh kekar sulit dibedakan hanya dari wajah.
5	American Pit Bull Terrier → Boxer (0,69; 0,26)	Close-up sudut lebar dengan mulut terbuka dan bulu gelap berdetail rendah. Distorsi perspektif mengubah bentuk moncong sehingga ciri pembeda ras hilang (sudut ekstrem, pencahayaan).
6	Abyssinian → Bengal (0,64; 0,34)	Tubuh melingkar dengan wajah sebagian menunduk, latar ungu dan kain merah muda yang memberi color cast kuat. Warna latar yang tidak lazim dapat menggeser fitur (bias latar belakang, pose ekstrem).
7	Chihuahua → American Pit Bull Terrier (0,62; 0,23)	Anjing berada di bawah kursi, sebagian tubuh tertutup kaki kursi (oklusi), dan lampu kilat menimbulkan mata merah. Bulu pendek cokelat muda memicu prediksi ras anjing berbulu pendek lain.

#	GT → Prediksi (conf; P(true))	Hipotesis penyebab
8	Abyssinian → Bengal (0,60; 0,38)	Mata tertutup, tampak samping, warna oranye-cokelat hangat, serta latar pameran dengan orang di belakang. Kasus paling dekat dengan batas keputusan; ciri wajah tidak tampak (pose, gangguan latar).

Pola yang terlihat pada delapan sampel: tiga merupakan Abyssinian yang diprediksi Bengal (dua ras kucing berbulu pendek dengan warna cokelat-oranye), tiga melibatkan ras anjing bertubuh kekar (Bulldog, Pit Bull, Boxer), dan sisanya Chihuahua dengan tampilan atipikal atau terhalang. Pola ini menunjukkan bahwa kesalahan terkonsentrasi pada ras yang secara visual berdekatan, bukan tersebar acak, dan diperparah oleh kondisi pengambilan gambar (close-up, oklusi, latar dominan).

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Rekomendasi. Untuk skenario data terbatas (±1.400 citra latih, 10 kelas, domain dekat ImageNet), pelatihan dari nol tidak layak (Macro F1 0,49). Mulailah dengan feature extraction (B2): hanya 5.130 parameter, stabil, dan memberi Macro F1 0,9396. Fine-tuning layer4 dengan differential learning rate (B3) memberi hasil setara pada data ini dan konvergen lebih cepat dalam jumlah epoch, tetapi wajib disertai early stopping dan pemulihan bobot terbaik karena validation loss terbaiknya muncul sangat awal; pilih B3 bila ada indikasi domain berbeda dari ImageNet atau data bertambah (hal ini belum diuji pada studi ini). Augmentasi tetap layak dipertahankan sebagai regularizer karena mengecilkan gap, namun manfaat akurasinya perlu diverifikasi per kasus.

Limitasi. (1) Single seed (42); B3 dan B4-b berkonfigurasi sama tetapi berbeda 0,0135 pada Macro F1, sehingga selisih di bawah ±1,5 poin tidak dapat dibedakan dari noise; seed juga hanya diatur sekali di awal, bukan per eksperimen, sehingga run tidak independen. (2) Test set hanya 298 citra: satu citra setara 0,34 poin akurasi dan galat baku akurasi sekitar 1,4 poin (±2,7 poin pada interval 95%). (3) Hanya 10 kelas dari subset satu dataset yang domainnya dekat ImageNet. (4) B1 dibatasi 20 epoch dan belum konvergen. (5) B1–B3 dilatih dengan augmentasi, sehingga efek augmentasi hanya diisolasi pada B4 (konfigurasi B3). (6) Learning rate dan hyperparameter lain tidak dituning. (7) Durasi diukur pada GPU Colab bersama (data loading dapat menjadi bottleneck) sehingga bersifat indikatif. (8) B5 dan analisis Grad-CAM tidak dilaksanakan.

Lampiran: Pernyataan Penggunaan AI (AI Disclosure Statement)

Alat: Claude (Anthropic). **Ruang lingkup:** membantu menyusun draft jawaban Bagian A, kerangka dan draft narasi laporan, skrip konsolidasi metrik, serta merangkum hasil dari berkas log.

ChatGPT(Open AI) membantu dalam menulis kode